

Comparação entre TTM2 e FlowState para Previsão de Energia de Prosumers


Um estudo sobre modelos de fundação para séries temporais da família IBM

Granite

Disciplina: Inteligência Artificial / ICD | ADS | 2026-1

O Desafio da Previsão Energética

- **Prosumers:** consumidores que também produzem energia (ex: painéis solares).
- Geração distribuída é altamente **intermitente** (depende de clima, horário, estação do ano).
- Operadores da rede precisam de previsões precisas para garantir o equilíbrio entre oferta e demanda.
- Modelos de fundação (*time series foundation models*) prometem realizar previsão sem necessidade de treinamento específico (*zero-shot*).




Dados: Enefit — Predict Energy Behavior of Prosumers

- **69 unidades de previsão** (combinando condado, tipo consumidor e produto).
- **Período:** set/2021 a mai/2023 (~21 meses).
- **Alvos:** consumo (*import*) e geração (*export*).
- **Covariáveis:** clima, radiação, preços.

Arquivo de Dados	Tamanho	Descrição
train.csv	94 MB	Séries temporais principais (alvos)
forecast_weather.csv	745 MB	Previsões meteorológicas (futuro)
historical_weather.csv	130 MB	Clima histórico medido (passado)
electricity_prices.csv	< 5 MB	Preços do mercado de energia

Dados: Enefit — Predict Energy Behavior of Prosumers

Populacao por condado — Estonia (2023)



TTM2 vs FlowState – IBM Granite TSFM Family

TinyTimeMixer v2 (TTM2)

NeurIPS 2024


- **Arquitetura:** MLP Mixer (baseado em blocos densos)
- **Parâmetros:** ~805 mil (Modelo 1M)
- **Contexto:** de 52 a 1536 timestamps (utilizamos 512)
- **Horizonte:** de 16 a 720 timestamps
- **Escolha de contexto+horizonte:** fixo, determinado pelo modelo
- **Modos de uso:** Zero-shot e Fine-tuning
- **Channel Mixing:** Faz uso de múltiplas features (não só o target) para detectar padrões nos dados

FlowState r1.1

arXiv 2025


- **Arquitetura:** State Space Model (SSM) + Functional Basis Decoder
- **Parâmetros:** 9.1 milhões (r1.0), 18.5 milhões (r1.1)
- **Contexto:** 2048 timesteps (r1.0), 4096 (r1.1)
- **Horizonte:** flexível
- **Modos de uso:** Apenas Zero-shot suportado

TTM2 vs FlowState – IBM Granite TSFM Family



Metodologia

- **Seis configurações avaliadas:** Persistence, Seasonal Naive, TTM2 zero-shot (L2), TTM2 fine-tuned, FlowState r1.0 (ctx512 e ctx2048), FlowState r1.1.
- **Hardware:** GPU GTX 1650 (4GB VRAM) — execução 100% local, sem nuvem.
- **Métrica primária:** SMAPE (Symmetric Mean Absolute Percentage Error), por ser mais robusto a valores próximos de zero (comum na geração noturna).
- **Otimização:** Fine-tuning supervisionado utilizando Design of Experiments (DoE) fatorial 2^3 .




Comparação Principal – MAE e SMAPE (média 69 unidades)

Modelo	Export MAE (Geração)	Export SMAPE	Import MAE (Consumo)	Import SMAPE
Persistence	420,6	159,5%	136,5	60,5%
Seasonal Naive	238,3	94,0%	102,5	39,9%
TTM2 zero-shot	202,3	106,4%	107,7	46,2%
FlowState ctx2048	181,7	99,6%	92,4	39,6%

** FlowState supera as baselines e o TTM2 em praticamente todas as métricas agregadas.*

MAE por Modelo – Geração e Consumo




Barras em destaque indicam o melhor modelo em cada métrica. O FlowState (contexto 2048) vence em 3 de 4 células avaliadas.

E se somarmos todas as 69 unidades? (Agregação Nacional)

- A soma das 69 unidades reduz drasticamente o ruído local e produz estimativas mais suaves para todo o sistema estoniano.
- MAPE de consumo cai de alarmantes 355% (média por unidade devido a zeros) para apenas **28,5%** (nacional).
- O SMAPE de consumo cai de ~40% para cerca de **20%**.

Modelo	Export MAE	Import MAE	Import SMAPE
Persistence	27.310	6.563	27,6%
TTM2 zero-shot	11.935	5.704	23,7%
FlowState ctx2048	9.862	4.542	20,0%



Limitações e Lições Aprendidas

⚠ Limitações Técnicas

- Dataset geograficamente limitado à Estônia (clima específico).
- Período de teste restrito a 4 dias (pode não capturar anomalias extremas).
- Modelos TSFM foram usados sem covariáveis meteorológicas (apenas histórico univariado).
- Fine-tuning full-shot foi validado computacionalmente em apenas 1 das 69 unidades. (few-shot em outros)

💡 Lições Aprendidas

- **Impacto do Channel Mixing:** Separar o dataset em um .csv para cada série temporal (69 arquivos separados) nos impede de usar Channel Mixing, limitando a capacidade do modelo de aprender com dados de outras séries.
- **Ilusão de Acurácia:** Agregar resultados (como medir baselines pelo agregado nacional) pode fazer a acurácia das previsões parecer melhor do que realmente é, devido à Lei dos Grandes Números.
- **Seleção de Covariáveis:** O uso de covariáveis, embora fora do escopo atual, deve ser extremamente criterioso. Poucas covariáveis com alta correlação são preferíveis a muitas covariáveis fracas.

Obrigada!

Perguntas?

 contato@email.com

 github.com/ifsc-sj-projetos-ia/time-series-foundation-models